Personal RAG Assistant

ระบบผู้ช่วย AI อัจฉริยะสำหรับค้นหาและวิเคราะห์เอกสารส่วนตัว
เพิ่มประสิทธิภาพด้วยเทคโนโลยี LangChain และ Gemini 2.0 Flash

Personal Document Assistant · Powered by ChromaDB

RAG คืออะไร?

Retrieval-Augmented Generation คือการนำความสามารถของ AI (LLM) มาเชื่อมต่อกับฐานข้อมูลเอกสารส่วนตัวของคุณ

- **ลดการมโน (Hallucination):** ตอบตามเอกสารจริง
- **อ้างอิงแหล่งที่มา:** บอกไฟล์และเลขหน้าชัดเจน
- **ข้อมูลเป็นปัจจุบัน:** ไม่ต้องรอ Train AI ใหม่

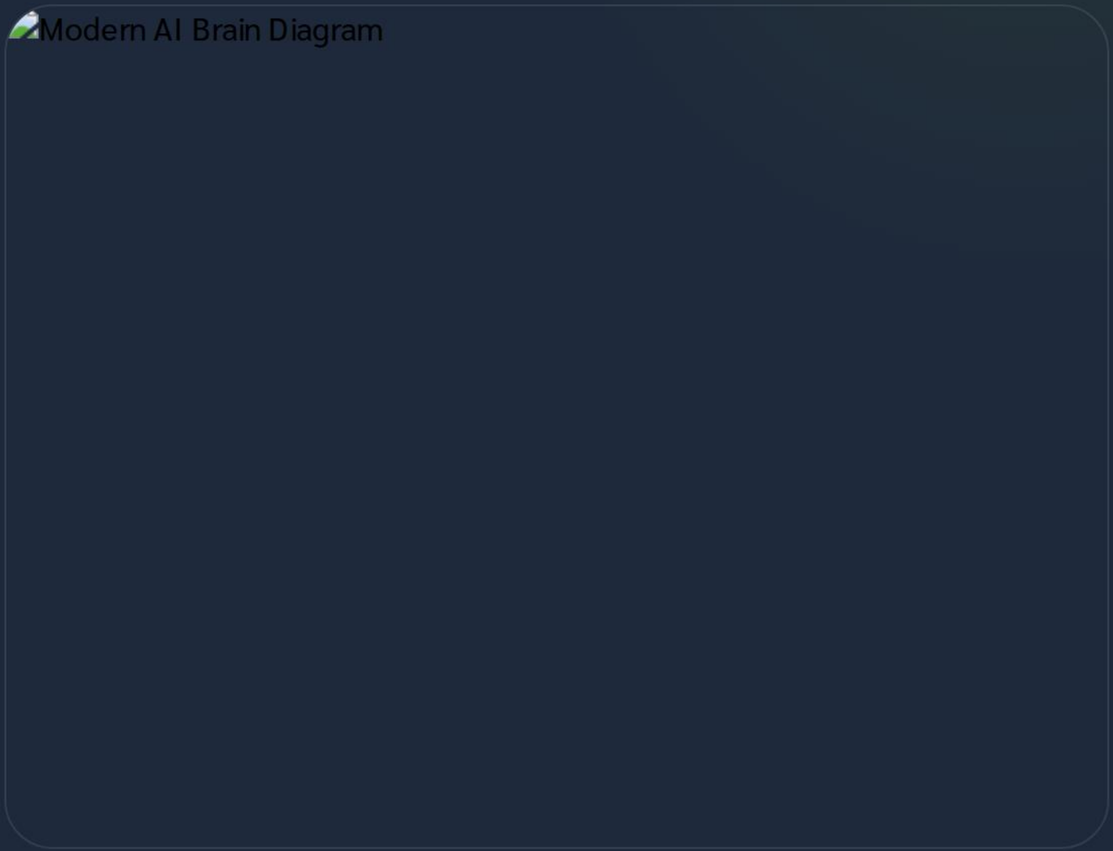

ความสามารถหลัก

รองรับหลากหลายไฟล์

อ่านไฟล์ `.pdf` และ `.txt` พร้อมระบบตรวจจับภาษาไทยอัตโนมัติ (UTF-8, CP874)

ค้นหาเชิงความหมาย

ไม่ต้องจำคำเป๊ะๆ ถามด้วยคำพูดปกติ AI จะหาข้อมูลที่เกี่ยวข้องที่สุดมาให้ด้วย Vector Search

Smart Ingestion

ป้องกันการเก็บข้อมูลซ้ำด้วย SHA-256 Hash ตรวจสอบเฉพาะไฟล์ใหม่หรือไฟล์ที่แก้ไขเท่านั้น

โครงสร้างระบบ

Phase 1: Data Ingestion

อ่านเอกสาร -> หั่นข้อความเป็นชิ้นๆ (Chunks) -> สร้าง Vector -> บันทึกลง ChromaDB

Phase 2: Retrieval & Chat

รับคำถาม -> ดึงข้อมูลที่เกี่ยวข้อง (Top-K) -> ส่งให้ Gemini ประมวลผล -> ตอบคำถาม

สเปกและโมเดลที่ใช้งาน

องค์ประกอบ	เทคโนโลยี / โมเดล	จุดเด่น
Embedding Model	`gemini-embedding-2`	แม่นยำสูง รองรับภาษาไทยได้ดีเยี่ยม
LLM Engine	`gemini-2.0-flash`	ประมวลผลเร็วมาก ทรงพลัง และมีค่าใช้จ่ายต่ำ
Vector Database	ChromaDB (Local)	เก็บข้อมูลบนเครื่อง ใช้งานง่าย ไม่ต้องพึ่ง Cloud
Framework	LangChain	มาตรฐานสากล ยืดหยุ่น และต่อยอดได้ไกล

4 ขั้นตอนการเริ่มต้น

1

ติดตั้ง

ลง Library จาก `requirements.txt`

2

ตั้งค่า

ใส่ API Key ในไฟล์ `.env`

3

Ingest

รัน `ingest.py` เพื่อเตรียมฐานข้อมูล

4

ถาม-ตอบ

รัน `chat.py` เพื่อเริ่มใช้งาน AI

การจัดการ Chunk ข้อมูล

1000

Chunk Size (ตัวอักษร)

100

Overlap (ตัวอักษร)

80

Batch Size

การตั้งค่า Overlap ช่วยให้ AI เข้าใจบริบทระหว่างชิ้นส่วนของข้อความได้ต่อเนื่องและแม่นยำยิ่งขึ้น

กระบวนการ Ingestion

ระบบใช้ **Smart Pipeline** ในการจัดการไฟล์:

- **SHA-256 Hashing:** ตรวจความเปลี่ยนแปลง
- **Recursive Splitting:** หั่นข้อมูลตามโครงสร้าง
- **Batch Saving:** บันทึกข้อมูลแบบเป็นกลุ่ม

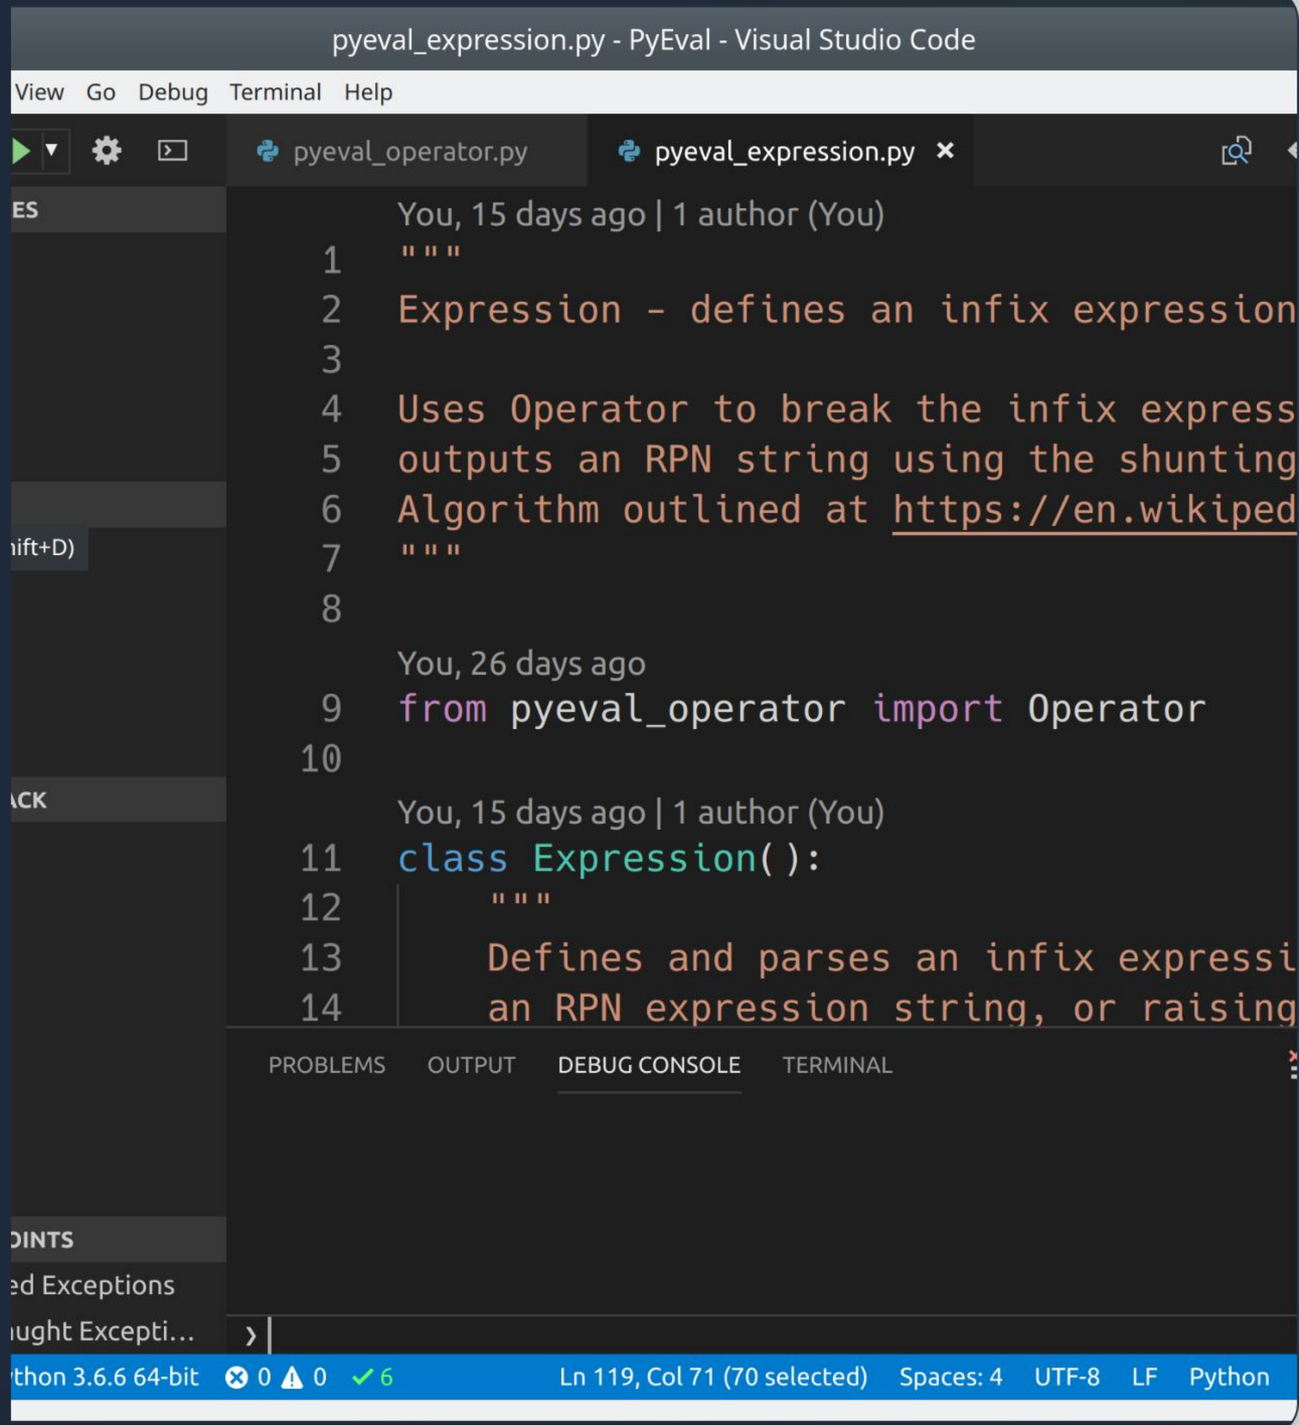

Retrieval & Chat Engine

หัวใจสำคัญของการค้นหาและสร้างคำตอบจาก AI

ความปลอดภัยและความเป็นส่วนตัว

🔒 **Local Database:** ฐานข้อมูล Vector เก็บอยู่ในเครื่องของคุณ ไม่รั่วไหลไป Cloud

🔑 **API Key Security:** เก็บความลับใน `.env` ไม่ Hardcode ในโปรแกรม

📤 **Minimal Exposure:** ส่งเฉพาะ Chunks ที่จำเป็นไปประมวลผลเท่านั้น

โครงสร้างไฟล์สำคัญ

ingest.py

ทำหน้าที่โหลด หั่น และบันทึกข้อมูลลง Vector DB

chat.py

อินเตอร์เฟซหลักสำหรับคุยกับ AI และค้นหาข้อมูล

vector_db/

โฟลเดอร์เก็บข้อมูลมิติ (Vectors) ทั้งหมด

คำถาม?

ขอบคุณที่รับชมการนำเสนอ Personal RAG Assistant

สร้างระบบ RAG ของคุณเองได้แล้ววันนี้

GitHub: `your-repo-link` | พัฒนาโดยใช้ LangChain & Gemini

Image Sources

https://static.vecteezy.com/system/resources/previews/071/049/005/non_2x/modern-ai-brain-background-showing-blue-circuits-and-technology-design-representing-artificial-intelligence-digital-innovation-machine-learning-and-futuristic-concept-vector.jpg

Source: www.vecteezy.com

---

https://files.realpython.com/media/vscode-debug-screen.647a68278472.png

Source: realpython.com

Thumbnail for pngtree.com

https://png.pngtree.com/png-clipart/20241001/original/pngtree-3d-secure-document-file-icon-clipart-png-image_16137828.png

Source: pngtree.com